

Introducción a TinyML con Keras y TensorFlow Lite

Robótica

Alberto Díaz Álvarez y Guillermo Iglesias Hernández Departamento de Sistemas Informáticos - Universidad Politécnica de Madrid 8 de octubre de 2023

License CC BY-NC-SA 4.0

Introducción a TinyML

¿Qué es esto de TinyML?



El término se refiere a la implementación de modelos de aprendizaje automático (ML) en dispositivos de recursos limitados

 Vamos, en microcontroladores y otros dispositivos de hardware de baja potencia y poca memoria

El objetivo principal es llevar la inteligencia artificial *al borde*

• Es decir, a los dispositivos que interactúan con el mundo real, como robots, drones, wearables, etc.

TensorFlow Lite, Keras, y otros frameworks proporcionan las herramientas necesarias para desarrollar y desplegar modelos de ML en microcontroladores¹²³

¹ https://www.sciencedirect.com/science/article/pii/S1319157821003335

² https://analyticsindiamag.com/how-tensorflow-lite-fits-in-the-tinyml-ecosystem/

³ https://www.tensorflow.org/lite/microcontrollers?hl=es-419



Importancia en el edge computing

Los modelos de ML en el *borde* tienen varias ventajas, entre las que detacan:

- Latencia: Pueden procesar datos y tomar decisiones en tiempo real sin depender de una conexión a un servidor centralizado
- **Privacidad**: Al procesar los datos localmente en el dispositivo, pueden preservar la privacidad del usuario ya que los datos sensibles no necesitan ser transmitidos
- Conectividad: Pueden operar de manera efectiva incluso en entornos con conectividad limitada o nula, algo crítico para muchas aplicaciones en tiempo real
- Consumo de Energía: Los microcontroladores son conocidos por su eficiencia energética, lo que permite implementaciones de ML de baja potencia, extendiendo la vida útil de la batería en dispositivos portátiles
- Costo: La computación en el borde puede reducir los costos asociados con la transmisión de datos y el procesamiento en la nube

TensorFlow Lite (TFLite)

¿Qué es TensorFlow Lite?



Solución ligera de TensorFlow diseñada para dispositivos móviles y embebidos

• Permite la inferencia en local⁴, lo que mejora latencia, privacidad y eficiencia

Principales características:

- Eficiencia de memoria: Diseñado para usar solo algunos KiB de memoria
- Independencia del sistema operativo: No requiere compatibilidad con el sistema operativo, ni bibliotecas C o C++ estándar, ni asignación de memoria dinámica
- **Soporte para diversos microcontroladores**: P.ej. Arduino, ESP32, y otros basados en la arquitectura ARM Cortex-M
- Herramientas para la optimización del tamaño y rendimiento del modelo

Está diseñado específicamente para ejecutar modelos de ML en microcontroladores y otros dispositivos de recursos limitados

Flujo de trabajo con Keras y TensorFlow Lite



Kera es un API de alto nivel para redes neuronales escrita en Python

Se ejecuta sobre TensorFlow (y soporta otros backends como Theano)

El flujo de trabajo para crear un modelo de ML con Keras y TensorFlow Lite es el siguiente:

- 1. Entrenar el modelo con Keras,
- 2. Convertir el modelo a TensorFlow Lite,
- 3. Optimizar el modelo para su uso en microcontroladores,
- 4. **Desplegar** el modelo en el microcontrolador³.

Keras para el desarrollo y TensorFlow Lite para la implementación facilitan el desarrollo de aplicaciones de TinyML

¡GRACIAS!