

Programación de softbots

Robótica - Grado en Ingeniería de Computadores

Departamento de Sistemas Informáticos

E.T.S.I. de Sistemas Informáticos - Universidad Politécnica de Madrid

License CC BY-NC-SA 4.0

Objetivos de aprendizaje de hoy

- Entender cómo se comunican dos **aplicaciones** a través de **Internet** (HTTP, APIs, REST)
- Dominar el **web scraping** en profundidad: cuándo usarlo, cómo hacerlo bien y sus límites legales y éticos
- Comprender formalmente qué es un **softbot**
- Conocer los **patrones de programación** necesarios para que un softbot funcione de forma robusta y sostenida en el tiempo
- Situar todo esto en el **panorama actual**: extracción asistida por IA y agentes que operan un navegador

Bloque 1

Servicios accesibles a través de Internet

El modelo cliente-servidor


Es el modelo de comunicación sobre el que se construye toda la Web:

- **Cliente:** solicita recursos (por ejemplo, nuestro softbot)
- **Servidor:** proporciona los recursos solicitados

Una sesión se inicia cuando el cliente envía una petición al servidor:

1. El cliente establece una conexión (típicamente TCP) con el servidor
2. El cliente envía una **petición** (**request**) y espera respuesta
3. El servidor procesa la petición y envía una **respuesta** (**response**), incluyendo un **código de estado**

El modelo cliente-servidor



Fuente: <https://www.geeksforgeeks.org/system-design/client-server-model/>

El protocolo HTTP

Hypertext Transfer Protocol (HTTP), diseñado en 1990, es la base de la comunicación de datos en la Web.

- Protocolo a nivel de aplicación, construido sobre TCP/IP
- Puerto estándar 80 (HTTP) y 443 (HTTPS, la versión cifrada)
- Hoy en día se usa mayoritariamente HTTP/2 (RFC 7540) y, cada vez más, HTTP/3
- Es lo bastante abierto como para no impedir el desarrollo de aplicaciones de terceros, como nuestros softbots

HTTP se usa principalmente para transmitir **recursos**:

- Un recurso es un fragmento de información identificable mediante una URL
- Puede ser un archivo estático o una salida generada dinámicamente

URL: identificando recursos en la Web

Una **Uniform Resource Locator** (URL) tiene la siguiente estructura:

```
protocolo://servidor:puerto/path/hasta/el/recurso?query=con&algun=parametro
```

Por ejemplo:

```
https://www.google.com/search?q=boniato+al+horno&client=gws-wiz-serp
```

- Si no se especifica el puerto, se usa el puerto por defecto del protocolo (HTTP: 80, HTTPS: 443)
- La parte `?query=con&algun=parametro` se conoce como **query string**

Mensajes en HTTP: request y response

Toda comunicación HTTP se basa en dos tipos de mensaje:

- **Request:** mensaje enviado por el cliente al servidor
- **Response:** mensaje enviado por el servidor al cliente

Ambos comparten estructura, con diferencias:

- Ambos poseen cabeceras con metainformación (**headers**)
- Ambos pueden incluir un cuerpo adicional con datos
- La request indica el **método** y el **recurso** al que se quiere acceder
- La response indica el **código de estado** de la respuesta

La estructura exacta de los mensajes difiere entre HTTP/1.1 y HTTP/2, pero las bibliotecas de Python nos abstraen de ese detalle.

Métodos HTTP

Método	Propósito
GET	Solicita un recurso
HEAD	Solicita solo los metadatos de un recurso
POST	Envía datos al servidor (p. ej. crear un recurso)
PUT	Envía un recurso completo para reemplazar uno existente
PATCH	Envía una actualización parcial de un recurso
DELETE	Elimina un recurso

Esto es la teoría, porque en la práctica cada servidor implementa lo que necesita.

Códigos de estado (status codes)

Números de tres dígitos que indican el resultado de la petición:

- **1xx**: información
- **2xx**: éxito (p. ej. 200 OK, 201 Created)
- **3xx**: redirección (p. ej. 301 Moved Permanently)
- **4xx**: error del cliente (p. ej. 404 Not Found, 429 Too Many Requests)
- **5xx**: error del servidor (p. ej. 500 Internal Server Error)

Al igual que los métodos, son un estándar, pero no son de obligado cumplimiento

Códigos de estado (status codes)



Fuente: <https://tracy.hashnode.dev/http-response-status-codes>

Servicios web y APIs

Un **servicio web** es un conjunto de protocolos y estándares que permiten la comunicación entre aplicaciones, normalmente sobre HTTP.

- Un conjunto de servicios web con un propósito común se denomina **API** (**Application Programming Interface**)
- Para nuestros softbots, las APIs son la forma más limpia de **percibir y actuar** sobre un sistema externo, mucho más fiable que interpretar una página web pensada para humanos

Históricamente, algunos estándares (SOAP, WSDL) formalizaban mucho esta comunicación; hoy dominan estilos más ligeros como **REST**, con datos en JSON.

El estilo arquitectónico REST

Representational State Transfer (REST) **no es un protocolo**, es un conjunto de principios de diseño para construir servicios web (Fielding, 2000):

- **Interfaz uniforme**: la información se envía en un formato estándar (JSON, XML...)
- **Sin estado**: cada petición se resuelve de forma independiente (es inherente a HTTP)
- **Distribuido**: permite que varios servidores trabajen juntos
- **Cacheable**: las respuestas pueden almacenarse en caché para mejorar el rendimiento
- **Código bajo demanda (opcional)**: el servidor puede enviar código ejecutable al cliente

Las APIs que siguen estos principios se llaman **API RESTful**.

Anatomía de una API RESTful

Una petición a una API RESTful típica requiere:

- **URL:** la ruta hacia el recurso o servicio
- **Método:** la acción a realizar
 - GET /games (listar) · GET /games/1 (un elemento)
 - POST /games (crear) · PUT/PATCH /games/1 (actualizar)
 - DELETE /games/1 (eliminar)
- **Cuerpo:** la información enviada (en POST, PUT, PATCH)
- **Cabeceras:** información adicional, como datos de autenticación

Es el estándar más extendido hoy en día, pero no es obligatorio ni universal.

API RESTful: Ejemplo

```
{
  - {
    id: 136095779,
    node_id: "MDEwOlJlcG9zaXRvcnkzMzYwOTU3Nzk=",
    name: "agile-week",
    full_name: "timwheelercom/agile-week",
    private: false,
    - owner: {
      login: "timwheelercom",
      id: 17229444,
      node_id: "MDQ6VXNlcjE3MjI5NDQ0",
      avatar_url: "https://avatars1.githubusercontent.com/u/17229444?v=4",
      gravatar_id: "",
      url: "https://api.github.com/users/timwheelercom",
      html_url: "https://github.com/timwheelercom",
      followers_url: "https://api.github.com/users/timwheelercom/followers",
      following_url: "https://api.github.com/users/timwheelercom/following{/other_user}",
      gists_url: "https://api.github.com/users/timwheelercom/gists{/gist_id}",
      starred_url: "https://api.github.com/users/timwheelercom/starred{/owner}/{/repo}",
      subscriptions_url: "https://api.github.com/users/timwheelercom/subscriptions",
      organizations_url: "https://api.github.com/users/timwheelercom/orgs",
      repos_url: "https://api.github.com/users/timwheelercom/repos",
      events_url: "https://api.github.com/users/timwheelercom/events{/privacy}",
      received_events_url: "https://api.github.com/users/timwheelercom/received_events",
      type: "User",
      site_admin: false
    },
  },
}
```

Fuente: <https://codesnippet.io/github-api-tutorial/>

Formatos de intercambio: JSON y XML

- **JSON** (**JavaScript Object Notation**): formato ligero, basado en pares clave-valor, hoy dominante en APIs REST
- **XML** (**eXtensible Markup Language**): formato basado en etiquetas anidadas, más verboso, aún presente en sistemas heredados y en SOAP

```
{"id": 1, "titulo": "Ejemplo", "disponible": true}
```

```
<juego id="1"><titulo>Ejemplo</titulo><disponible>true</disponible></juego>
```


Otros estilos de API (contexto)

No todo es REST. Conviene conocer, aunque sea brevemente, otras alternativas que te puedes encontrar:

- **SOAP**: protocolo más formal y rígido que REST, con contratos definidos en WSDL; hoy en desuso frente a REST pero aún presente en sistemas empresariales heredados (banca, administración pública)
- **GraphQL**: el cliente especifica exactamente qué datos necesita en una única petición, evitando pedir de más o de menos
- **gRPC**: protocolo binario de alto rendimiento basado en HTTP/2, muy usado en comunicación entre microservicios

Para un softbot que consume APIs de terceros, lo habitual seguirá siendo REST + JSON, pero es importante reconocer estas alternativas cuando aparezcan.

Autenticación y autorización

La mayoría de APIs útiles para un softbot requieren identificarse:

- **API key**: una cadena fija (como una contraseña) que se envía en la petición (cabecera o parámetro), la forma más simple
- **OAuth 2.0**: estándar para delegar acceso sin compartir contraseñas; el softbot obtiene un **token**¹ de acceso tras un proceso de autorización
- **JWT (JSON Web Token)**: token autocontenido y firmado, muy usado para transmitir identidad y permisos de forma compacta. Se suele combinar con OAuth 2.0

Un softbot en producción nunca debe llevar estas credenciales escritas directamente en el código.

¹: Suele ser un archivo .json

Límites de uso: rate limiting y paginación

Casi ninguna API es de uso ilimitado:

- **Rate limiting:** número máximo de peticiones permitidas en una ventana de tiempo; suele indicarse en cabeceras como `X-RateLimit-Remaining`
- **Paginación:** cuando una colección es muy grande, la API la devuelve en páginas (`?page=2&per_page=50`) en lugar de todo de golpe
- **Cuotas:** límites más amplios, por ejemplo mensuales, ligados a un plan de uso

Un softbot bien diseñado **respeta** estos límites, tanto por corrección técnica como por buena convivencia con el servicio.

Comunicación en tiempo real: WebSockets y webhooks

No todo es petición-respuesta puntual:

- **WebSockets**: conexión persistente y bidireccional entre cliente y servidor, útil cuando el softbot necesita recibir actualizaciones constantes (p. ej. temperatura en tiempo real)
- **Webhooks**: en lugar de que el softbot pregunte constantemente ("¿hay algo nuevo?"), el servidor le **avisa** enviando una petición HTTP a una URL que el softbot expone, en el momento en que ocurre un evento²

²: Esta idea será clave cuando hablemos de arquitecturas de softbot orientadas a eventos frente a sondeo periódico.

Bloque 2

Web scraping

¿Por qué scrapear si existen las APIs?

El **web scraping** es la técnica para **extraer información de sitios web** mediante software, navegando e interpretando el HTML como lo haría un humano con un navegador.

Es la alternativa cuando:

- El sitio **no ofrece una API** pública
- La API existe pero es **insuficiente** (le faltan datos que sí están en la web)
- Se necesita **verificar** que lo que ve un usuario real coincide con lo que devuelve la API

Se basa en dos procesos:

1. **Navegación** por los sitios web (procesos llamados **spiders** o **crawlers**)
2. **Extracción** de datos del contenido (**scraping** propiamente dicho)

Inconvenientes del web scraping

Comparado con usar una API, el scraping:

- Es una técnica **más costosa** de desarrollar y mantener
- Genera **más tráfico** entre cliente y servidor (se descarga la página completa, no solo el dato)
- Es **sensible a cambios** en la estructura de las páginas (un rediseño puede romper el scraper)
- Obliga a respetar las **condiciones de uso** del sitio, sean o no legalmente vinculantes

Dominios de aplicación

- **Automatización de negocio:** evitar recopilar información manualmente de múltiples fuentes
- **Estudios de mercado:** agregación de datos públicos
- **Generación de leads:** listas de clientes potenciales
- **Seguimiento de precios:** e.g. [CamelCamelCamel](#) para precios en Amazon
- **Noticias y contenidos:** agregadores
- **Monitorización de marca:** qué se dice de una empresa en Internet
- **Mercado inmobiliario:** qué se vende y a qué precio


Estructura de una página web: HTML y el DOM

Para scrapear con criterio hay que entender qué se está leyendo:

- **HTML**: lenguaje de marcado que define el contenido y la estructura de una página
- **DOM** (**Document Object Model**): representación en forma de **árbol** de ese HTML una vez cargado, donde cada etiqueta es un nodo
- **CSS**: además de dar estilo, sus **selectores** (clases, identificadores) son la forma más habitual de localizar un elemento concreto dentro del árbol

```
<div class="producto" id="p1">  
  <h2>Claveles</h2>  
  <span class="precio">10.59€</span>  
</div>
```

Estructura de una página web: HTML y el DOM



Localizar contenido: selectores CSS y XPath

Dos lenguajes de consulta para "apuntar" a un nodo concreto del DOM:

- **Selectores CSS:** `.precio`, `#p1`, `div.producto > span` — sintaxis familiar si ya conoces CSS
- **XPath:** lenguaje de consulta más potente, desarrollado por el W3C como parte de la recomendación XSLT, que permite navegar el árbol con más precisión (W3C, 1999)

```
//div[@class="producto"]/span[@class="precio"]/text()
```

XPath permite seleccionar elementos por nombre, atributos y posición, admite operadores lógicos y aritméticos, y accede sin problema a estructuras muy anidadas.

Scraping estático vs. dinámico

- **Contenido estático:** todo el HTML relevante llega ya completo en la respuesta del servidor — basta con descargar y parsear
- **Contenido dinámico:** la página se construye o completa **en el navegador**, ejecutando JavaScript después de la carga inicial

Esta distinción es crucial porque determina qué herramienta necesitas:

- Estático → librerías HTTP + parseo de HTML (rápido y barato)
- Dinámico → un **navegador real (o headless)** que ejecute el JavaScript antes de poder leer el resultado (más lento y costoso)

Herramientas para scraping estático

La biblioteca `urllib`

Forma parte de la biblioteca estándar de Python, no requiere instalación.

```
from urllib.request import urlopen, Request

request = Request('https://www.python.org/')
with urlopen(request) as response:
    received_bytes = response.read()
content = received_bytes.decode()
```

Permite enviar parámetros por `GET` (codificándolos con `urllib.urlencode`), enviar datos por `POST`, subir ficheros y leer las cabeceras de la respuesta.

- Es funcional pero verbosa, por eso en la práctica se usa más `requests`

Parámetros por GET

En el ejemplo anterior, la URL no incluía ningún parámetro

- En el caso de una petición GET, estos se añaden a la URL
- Sin embargo, hay que tener cuidado con la codificación de los caracteres especiales

Para ello, podemos usar la función `urlencode` de `urllib.parse`

```
from urllib.parse import urlencode

params = urlencode({'q': 'python'})
url = 'https://www.google.com/search?' + params
print(url)
```

Así nos aseguramos de que todo carácter especial es codificado correctamente

Datos por POST

Una petición de tipo POST envía los parámetros en el cuerpo de la petición

- No tiene sentido mandar parámetros porque no tendremos acceso a la *query string*
- POST es más flexible que GET, ya que permite enviar datos binarios (e.g. ficheros)

Para enviar datos por POST, basta con crear la *request* con datos:

```
data = urlencode({'key': 'value'}).encode()  
request = Request('https://httpbin.org/anything', data=data)  
with urlopen(request) as response:  
    print(response.read().decode())
```

Esto no funciona si el cuerpo de datos es vacío

- Se puede solucionar añadiendo el argumento `method='POST'` al crear la *request*
- De hecho con este argumento se especifica el método de la petición

Formularios y POST

Los formularios HTML se envían por POST por defecto

- Cada campo del formulario se envía como un parámetro diferente

Veamos los tipos más comunes:

- text, password, hidden, textarea, select, radio: Se envía el *name/value* del campo
- checkbox: Se envían tantos *name/value* como checkboxes estén marcados

Los formularios se pueden enviar también por GET

- En este caso, los parámetros se añaden a la URL

¿Y si queremos enviar ficheros?

De hecho, es una de las características de POST frente a GET

- Es similar al caso anterior, pero enviando el contenido de un fichero
- Es conveniente añadir ciertas cabeceras para indicar el tamaño y el tipo de contenido

Por ejemplo, para enviar una imagen PNG:

```
import os

image_path = 'images/python.png'
image_size = os.path.getsize(image_path)
image_data = open(image_path, 'rb')
request = Request('https://httpbin.org/anything', data=image_data)
request.add_header('Content-Length', image_size)
request.add_header('Content-Type', 'image/png')
with urlopen(request) as response:
    print(response.read().decode())
```

Cabeceras HTTP relevantes para un scraper

Estas cabeceras condicionan cómo nos "ve" el servidor:

- **Accept**: qué formatos entiende el cliente (HTML, JSON...)
- **Accept-Encoding**: qué compresión soporta (gzip, br...)
- **Accept-Language**: idioma preferido
- **User-Agent**: identifica el tipo de cliente (navegador, móvil...)³
- **Referer**: la URL desde la que se ha llegado, útil para simular un patrón de navegación humano³

```
request.add_header('User-Agent', 'Mozilla/5.0 (X11; Ubuntu; Linux x86_64) ...')
```

Cuanto más se parezcan estas cabeceras a las de un navegador real, menos probable es que el servidor bloquee la petición.

³: Clave para no destacar como scraper

¿Cómo leemos las cabeceras de una respuesta?

Toda petición conlleva una respuesta con cabeceras y (a veces) datos

- La biblioteca `urllib` las comprime en un objeto `HTTPMessage`

```
request = Request('https://www.python.org/')  
with urlopen(request) as response:  
    print(response.headers)
```

Este objeto se comporta como un diccionario

- Con el método `get` podemos obtener el valor de la cabecera indicada

Veamos algunas cabeceras útiles

Cabecera *Accept*

Indica al servidor web qué formato de datos entiende cliente

- Por ejemplo, si el cliente entiende HTML, JSON, XML, etc.

```
request = Request('https://httpbin.org/anything')  
request.add_header('Accept', 'application/json;q=0.9, */*;q=0.8')
```

El factor de calidad **q** indica la preferencia del cliente

- Se utiliza en las cabeceras que aceptan varios valores

Es importante que la cadena sea similar a la ofrecida por los navegadores

Cabecera *Accept-Encoding*

Notifica al servidor web qué algoritmo de compresión utilizar para gestionar la petición

- Por ejemplo, si el cliente entiende `gzip`, `deflate`, `br`, etc.
- Dicho de otro modo, si el cliente y el servidor pueden comprimir la información

```
request = Request('https://httpbin.org/anything')  
request.add_header('Accept-Encoding', 'gzip, deflate, br')
```

Esta cabecera es especialmente útil para reducir el tamaño de las respuestas

- Menos tiempo de espera y menos ancho de banda, win-win para cliente y servidor

El *encoding* `br` (Brotli) se usa para identificar scrapers, pero `urllib` ya lo soporta

Cabecera *Accept-Language*

Indica al servidor qué idiomas prefiere el cliente

- Se puede especificar un único idioma o una lista de idiomas
- Entra en juego cuando los servidores web no pueden identificar el idioma preferido

```
request = Request('https://httpbin.org/anything')  
request.add_header('Accept-Language', 'en-US, en;q=0.9, es;q=0.8')
```

Es un factor más a la hora de detectar comportamientos no humanos

- Puede ser útil hacer que los lenguajes se ajusten a la ubicación IP del cliente
- También es útil ajustar los valores de `q` para no destacar frente al resto de tráfico

Cabecera *User-Agent*

El servidor utiliza esta información para identificar y adaptar el contenido al cliente

- Por ejemplo, si el cliente es un navegador web, un teléfono móvil, un reproductor multimedia, etc.

```
request = Request('https://httpbin.org/anything')  
request.add_header('User-Agent', 'Mozilla/5.0 (X11; Ubuntu; Linux x86_64 ...')
```

Suelen seguir el formato:

```
(<navegador>) (<sistema>) <plataforma> (<detalles plataforma>) <extensiones>
```

Es importante porque ayuda a enmascarar el scraper como un navegador web

- Si el agente de usuario está mal formado, lo más normal es que el servidor lo bloquee

Cabecera *Referer*

Indica la URL de la página desde la que se ha hecho la petición

```
request = Request('https://httpbin.org/anything')  
request.add_header('Referer', 'https://www.google.com/')
```

Esta cabecera es importante para identificar patrones de uso en usuarios

- Y los usuarios no suelen entrar en páginas web de forma aleatoria
- Suelen venir de buscadores web, redes sociales, etc.

Es interesante especificar esta cabecera para que el agente parezca más "humano"

La biblioteca `requests`

Simplifica enormemente el trabajo frente a `urllib`:

- Gestión sencilla de cookies y sesiones
- Codificación automática de contenido y de URLs internacionalizadas
- Soporte simple para proxies, certificados SSL y streaming
- Conexiones persistentes (**keep-alive**) automáticas

```
bash
pip install requests
```

```
python
import requests
response = requests.get('https://httpbin.org/anything', params={'p1': 'v1'})
response.raise_for_status()
datos = response.json()
```

¿Cómo realizo una petición HTTP?

Tan sencillo como usar la función `get` de la biblioteca:

```
response = requests.get('https://httpbin.org/anything')
```

De hecho, cada método tiene su propia función:

- `get()`, `post()`, `put()`, `patch()`, `delete()`, `head()`, `options()`

Enviar parámetros también es sencillo, basta con usar el diccionario `params`:

```
response = requests.get('https://httpbin.org/anything', params={'p1': 'v1', 'p2': 'v2'})
```

Y establecer un tiempo máximo de respuesta con el parámetro `timeout`:

```
response = requests.get('https://httpbin.org/anything', timeout=5)
```

Envío de datos en peticiones POST/PUT/PATCH

En este caso, habría que utilizar el parámetro `data`:

```
response = requests.post('https://httpbin.org/anything', data={  
    'param1': 'val1',  
    'param2': 'val2'  
})  
response.text
```

No es necesario codificar los datos, la biblioteca lo hace por nosotros

¿Y si necesitamos especificar el tipo de contenido?

En ese caso jugamos con las cabeceras:

```
response = requests.post('https://httpbin.org/anything', data={
    'param1': 'val1',
    'param2': 'val2'
}, headers={'Content-Type': 'text/xml'})
response.text
```

¡E incluso con los datos!

```
response = requests.post('https://httpbin.org/anything',
    data='<?xml version="1.0" encoding="UTF-8"?><soap:Envelope...',
    headers={'Content-Type': 'text/xml'})
response.text
```

¿Y si necesitamos enviar un fichero?

Pues nada, para eso tenemos el parámetro `files`:

```
response = requests.post('https://httpbin.org/anything', files={  
    'file1': open('file1.txt', 'rb'),  
    'file2': open('file2.txt', 'rb')  
})
```

Aunque también podemos especificar explícitamente el nombre y tipo del fichero:

```
files = {'f1': ('cosa.pdf', open('algo.pdf', 'rb'), 'application/pdf')}  
response = requests.post('https://httpbin.org/anything', files=files)
```

Obteniendo información de la respuesta

El objeto de respuesta tiene muchos miembros interesantes, como lo son:

- `status_code`: Código de estado HTTP
- `headers`: Diccionario con las cabeceras de la respuesta
- `cookies`: Diccionario con las cookies de la respuesta
- `content`: Contenido de la respuesta
- `encoding`: Codificación de la respuesta (se puede establecer)
- `text`: Contenido de la respuesta en formato texto (decodificado)
- `history`: Información de todas las redirecciones que han ocurrido
 - Aunque se puede especificar `allow_redirects = False` para evitar redirecciones
- `json()`: Contenido de la respuesta en formato JSON
- `raise_for_status()`: Lanza una excepción si el código de estado no es 200

¿Cómo se pueden especifican las cabeceras?

Cualquier método de petición acepta un parámetro `headers`:

```
response = requests.get('https://httpbin.org/anything', headers={
    'Accept': 'application/json;q=0.9, */*;q=0.8',
    'Accept-Encoding': 'gzip, deflate',
    'Accept-Language': 'en-US, en;q=0.9, es;q=0.8'
})
response.headers
```


¿Cómo enviar **cookies** en una petición?

Aunque se puede perfectamente con `urllib`, con `requests` es mucho más sencillo:

```
jar = requests.cookies.RequestsCookieJar()  
jar.set('cookie1', 'v1', domain='httpbin.org', path='/')  
jar.set('cookie2', 'v2', domain='httpbin.org', path='/anything')  
response = requests.get('https://httpbin.org/anything', cookies=jar)  
response.text
```

⁵ De hecho, trabajar con el objeto `CookieJar` de `urllib` es bastante pesado, por eso ni lo comentamos

¿Cómo mantener sesiones?

```
session = requests.Session()  
session.get('https://httpbin.org/cookies/set?cookie1=val1')  
session.get('https://httpbin.org/cookies/set?cookie2=val2')  
response = session.get('https://httpbin.org/cookies')  
response.text
```

Autenticación

La biblioteca permite autenticarse con varios métodos:

```
auth = HTTPBasicAuth('user', 'passwd') # HTTPDigestAuth, HTTPProxyAuth, ...  
# auth =  
response = requests.get('https://httpbin.org/hidden-basic-auth/user/passwd', auth=auth)
```

¿Cómo podemos usar **proxies**?

```
proxies={'http': 'http://ip:puerto', 'https': 'https://ip:puerto'})  
requests.get('https://httpbin.org/anything', proxies=proxies)
```

Para mantenerlos en una sesión, se puede hacer de la siguiente forma:

```
proxies = {'http': 'http://ip:puerto', 'https': 'https://ip:puerto'}  
session = requests.Session()  
session.proxies.update(proxies)  
session.get('https://httpbin.org/anything')
```

BONUS TRACK: Peticiones a través de **Tor**

Podemos usar los proxies configurados para navegar a través de Tor:

```
proxies = {  
    'http': 'socks5://127.0.0.1:9050',  
    'https': 'socks5://127.0.0.1:9050'  
}  
requests.get('https://httpbin.org/anything', proxies=proxies)
```

Extrayendo información: expresiones regulares

Mecanismo compacto para definir patrones de texto que queremos localizar o extraer.

```
import re
texto = 'ababcababcbab'
patron = 'a(.*?)c' # el '?' hace el encaje "no voraz"
if m := re.search(patron, texto):
    print(m.group(1))
```

- `re.findall(patron, texto)` devuelve **todas** las coincidencias
- Flags útiles: `re.DOTALL`, `re.MULTILINE`, `re.IGNORECASE`
- Si se va a reutilizar mucho, conviene compilar la expresión: `re.compile(patron)`
- Herramientas online como regex101.com ayudan a depurar patrones complejos

⚠ **Aviso importante:** las expresiones regulares son frágiles ante HTML real (anidamiento, atributos en cualquier orden). Úsalas para texto simple, no para "parsear" HTML completo — para eso están XPath y los selectores CSS.

¿Qué pasa si buscamos muchos patrones?

Pues que usaremos `findall` en lugar de `search`

```
texto = 'ababcbababcbab'  
patron = 'a(.*?)c'  
print(re.findall(patron, texto))
```

En lugar de un objeto `match` nos devuelve una lista de cadenas

- Hay *flags* que vienen bien porque modifican el comportamiento de los metacaracteres:
 - `re.DOTALL`: `.` coincide con cualquier carácter, incluido el salto de línea `\n`
 - `re.MULTILINE`: `^` coincidirá con el comienzo de línea y `$` con el final de línea
 - `re.IGNORECASE`: Hace que las expresiones regulares sean insensibles a mayúsculas y minúsculas

Ganando eficiencia con expresiones regulares

Las expresiones regulares se compilan para ejecutarse sobre un texto

- Cada vez que usamos uno de sus métodos (e.g. `search`, `findall`, ...) compilamos la expresión

Es recomendable compilar una expresión previamente si la vamos a usar mucho

```
expr = re.compile('a(.*)c')  
expr.search('ababcababcb')  
expr.findall('ababcababcb')
```


Algunos consejos

Para extraer varios valores es muy cómodo dividir la cadena de la expresión en trozos

```
xtr = '.*?<a href="(.*?)"' # url  
xtr += '.*?<td>(.*?)</td>' # incidencia
```

Hay herramientas online que ayudan a explicar los patrones que necesitamos

- <www.regex101.com>

BeautifulSoup y selectores CSS

BeautifulSoup es la biblioteca más popular para parsear HTML de forma tolerante a errores, usando selectores CSS de forma muy legible.

```
pip install beautifulsoup4
```

```
import requests
from bs4 import BeautifulSoup

page = requests.get('https://httpbin.org')
soup = BeautifulSoup(page.content, 'html.parser')

titulo = soup.select_one('title').text
enlaces = [a['href'] for a in soup.select('a[href]')]
```

Es la opción recomendada cuando el HTML no está perfectamente formado

Extrayendo información: XPath con lxml

Cuando se necesita más precisión o rendimiento, lxml junto con XPath es una alternativa muy potente.

```
pip install lxml
```

```
import requests
from lxml import html

page = requests.get('https://httpbin.org')
tree = html.fromstring(page.content)
titulo = tree.xpath('//title/text()')

# Ejemplo: títulos de noticias de un portal
page = requests.get('https://www.bbc.com/news')
tree = html.fromstring(page.content)
noticias = tree.xpath('//a[@class="gs-c-block-link__overlay-link"]/text()')
```

El framework Scrapy


Cuando el proyecto crece (miles de páginas, varios sitios, necesidad de programar reintentos y exportación), conviene un framework dedicado en lugar de scripts sueltos.

Scrapy organiza el scraping en torno a tres conceptos:

- **Spiders**: definen cómo navegar un sitio y qué datos extraer de cada página
- **Pipelines**: procesan y almacenan los datos extraídos (limpieza, validación, guardado en base de datos)
- **Middlewares**: interceptan peticiones/respuestas para añadir comportamiento transversal (proxies, reintentos, rotación de **user-agent**)

Incluye de serie gestión de concurrencia, colas de peticiones y respeto configurable de `robots.txt` — todo lo que en los ejemplos anteriores tendríamos que programar a mano.

El framework Scrapy



Herramientas para scraping dinámico

¿Por qué necesitamos un navegador?

Cuando el contenido se genera con JavaScript **después** de la carga inicial, descargar el HTML crudo no sirve: hay que **ejecutar** la página como lo haría un navegador.

Para esto existen los **navegadores headless**: un navegador real, pero sin interfaz gráfica, controlado por código.

- Es de las pocas formas fiables de interpretar código del lado del cliente dentro de un softbot
- Es más lento y consume más recursos que las técnicas anteriores

La biblioteca **selenium**

Nació como entorno de pruebas para aplicaciones web, pero hoy se usa ampliamente como herramienta de scraping dinámico.

```
from selenium import webdriver
from selenium.webdriver.common.by import By

driver = webdriver.Firefox()
driver.get('https://httpbin.org/anything')

elemento = driver.find_element(By.ID, 'id')
elemento = driver.find_element(By.CSS_SELECTOR, 'selector')
elemento = driver.find_element(By.XPATH, '//etiqueta[@atributo="valor"]')
```

- **find_element**: primer elemento que cumple el criterio
- **find_elements**: lista de todos los elementos que lo cumplen

Interactuar con la página

Al emular un navegador real, podemos reproducir cualquier acción humana:

```
boton.click()  
campo_texto.send_keys('texto')  
formulario.submit()
```

Y esperar a que ocurran cosas de forma explícita, en lugar de usar pausas fijas:

```
from selenium.webdriver.support.ui import WebDriverWait  
from selenium.webdriver.support import expected_conditions as EC  
  
elemento = WebDriverWait(driver, 10).until(  
    EC.presence_of_element_located((By.ID, 'id'))  
)
```

Playwright como alternativa

Selenium sigue siendo el más veterano y extendido, pero **Playwright** (Microsoft) se ha consolidado como alternativa moderna con ventajas notables:

- Espera automática de elementos (menos necesidad de `WebDriverWait` manual)
- API más consistente entre Chromium, Firefox y WebKit
- Mejor soporte nativo para interceptar peticiones de red y depurar

```
from playwright.sync_api import sync_playwright

with sync_playwright() as p:
    browser = p.chromium.launch(headless=True)
    page = browser.new_page()
    page.goto('https://httpbin.org/anything')
    enlaces = [a.get_attribute('href') for a in page.query_selector_all('a')]
```

Para proyectos nuevos en 2026, Playwright es una opción interesante

Extracción asistida por IA

Una tendencia reciente es usar un **LLM** para interpretar el contenido de una página en lugar de escribir selectores CSS/XPath frágiles a mano:

- El HTML (o una versión simplificada) se pasa al modelo junto con una instrucción de qué extraer
- Es especialmente útil frente a páginas que cambian de estructura con frecuencia, o con contenido semi-estructurado (opiniones, descripciones libres)
- Servicios especializados combinan esta idea con infraestructura de scraping (proxies rotativos, renderizado JS, resolución de CAPTCHAs) empaquetada como API

Buenas prácticas técnicas

Un scraper bien construido:

- Respeta un **intervalo entre peticiones** (rate limiting propio), a ser posible con variación aleatoria
- Usa un **user-agent realista y actualizado**
- Maneja **errores de red y reintentos** con criterio (no reintentar infinitamente, usar **backoff** progresivo)
- **Cachea** lo que ya ha descargado para no repetir trabajo innecesario
- Usa **API cuando existe**, y reserva el scraping para lo que realmente lo necesita

Mecanismos anti-scraping

Es lógico que algunos sitios protejan sus datos. Ninguna medida es infalible, casi todo comportamiento de navegador es replicable, pero sí dificultan la tarea:

- **Análisis de comportamiento:** detectar patrones no humanos (velocidad, regularidad de clics)
- **Bloqueo de IP:** bloquear direcciones que acceden con demasiada frecuencia
- **CAPTCHA:** Completely Automated Public Turing test to tell Computers and Humans Apart
- **robots.txt:** fichero que indica qué rutas no deberían visitar los robots
- **HoneyPot:** enlaces trampa invisibles para humanos pero visibles para un scraper poco cuidadoso

Técnicas (legítimas) para evitar bloqueos

- **Rotación de user-agent** entre sesiones (manteniéndolo fijo dentro de una misma sesión)
- **Intervalos aleatorios** entre peticiones, proporcionales al volumen de contenido pedido
- **User-agents actualizados**
- **Proxies** para distribuir la carga entre varias IPs
- **Navegadores headless** cuando la interpretación de JavaScript es imprescindible
- **Evitar honeypots**: no seguir enlaces ocultos o sin sentido visual
- **Respetar robots.txt**
- **Usar la API oficial** cuando exista, en lugar de scrapear
- Ordenar las cabeceras de forma similar a como lo hace un navegador real

robots.txt y los nuevos estándares para la era de la IA

robots.txt (estandarizado como RFC 9309) es una **petición voluntaria** que los rastreadores de buena fe respetan⁴, el cumplimiento real ocurre a nivel de servidor o CDN.

Últimamente han surgido señales adicionales pensadas específicamente para agentes de IA:

- Diferenciación entre rastreadores de **búsqueda** (e.g. OAI-SearchBot) y de **entrenamiento** (e.g. GPTBot, Google-Extended), que un sitio puede permitir o bloquear por separado
- Propuestas de **ai.txt** / **llms.txt**, pensadas para expresar matices que robots.txt no puede (por ejemplo, "indexa esto, pero no lo uses para entrenar un modelo")

⁴: No tiene fuerza legal por sí mismo y no bloquea el acceso técnicamente

¿Es legal el web scraping?

Sigue moviéndose en una zona intermedia entre lo permitido y lo prohibido, y depende mucho del contexto:

- El scraping de páginas **públicas**, en sí mismo, generalmente no se considera un acceso no autorizado
- Pero **las condiciones de uso que se aceptan** (por ejemplo, al crear una cuenta) sí pueden ser exigibles por contrato, aunque los datos scrapeados sean públicos
- El tratamiento de **datos personales** añade otra capa: en la Unión Europea, el RGPD aplica independientemente de que el dato esté "públicamente accesible"
- En España, la Ley de Servicios de la Sociedad de la Información (LSSI-CE) no prohíbe explícitamente el web scraping

I am not a lawyer (IANAL), esto es una introducción para orientarte, no asesoramiento legal.

Jurisprudencia y marco 2026

Dos referencias que conviene conocer:

- **hiQ Labs v. LinkedIn**: hiQ scrapeaba perfiles públicos de LinkedIn con fines de analítica de RRHH. El Noveno Circuito de EE. UU. resolvió (2022) que scrapear páginas públicas **no** constituye un acceso no autorizado bajo la CFAA, pero el caso terminó con hiQ reconociendo haber **incumplido los términos de servicio** que sí había aceptado. La lección de doble filo: scrapear lo público no es "hackear", pero los contratos que aceptas sí son exigibles
- **Reglamento de IA de la UE (EU AI Act)**: desde 2026 exige a los proveedores de IA de propósito general documentar las fuentes de sus datos de entrenamiento y respetar las señales de exclusión de minería de texto y datos (**TDM opt-out**)

En 2026, la tendencia regulatoria es clara: pasar del "salvaje oeste" de la extracción de datos a exigir **trazabilidad y base legal documentada**, especialmente en la UE.

El nuevo panorama: agentes de IA frente a plataformas

Antes de 2024, el acceso automatizado a la web se regulaba de facto mediante dos mecanismos: la adhesión voluntaria a `robots.txt`, y técnicas de identificación de clientes automatizados

Con la llegada de agentes de IA que navegan y actúan de forma autónoma a gran escala, ese equilibrio se ha vuelto inestable, hay quien lo describe como una auténtica **carrera armamentística** entre plataformas y proveedores de agentes, apoyada todavía en precedentes legales pensados para el scraping tradicional, no para agentes autónomos. Esto está impulsando propuestas de una **nueva infraestructura normativa** específica para lo que ya se conoce como la **web agéntica**.

Bloque 3

Softbots


Recordatorio: ¿qué es un softbot?

Un **softbot** es un robot software que actúa en nombre de un usuario o proceso, usado para automatizar tareas repetitivas y tediosas.

Con todo lo visto, podemos concretarlo mucho más:

- Su **percepción** del entorno ocurre a través de servicios web (APIs) o de web scraping
- Su **acción** sobre el entorno ocurre también a través de esos mismos canales: llamadas a una API, envío de formularios, clics en una interfaz
- Su **arquitectura interna** (reactiva, deliberativa, híbrida, BDI, basada en LLM...) decide qué hacer con lo percibido

Softbot



Fuente (editada): https://www.researchgate.net/publication/201018712_Towards_a_Unified_View_of_the_Environments_within_Multi-Agent_Systems

Ciclo de vida típico de un softbot

1. **Inicialización:** carga de configuración, credenciales, estado previo si existe
2. **Percepción:** consulta a una API, scraping de una o varias páginas
3. **Decisión:** procesamiento de lo percibido según su arquitectura interna
4. **Acción:** llamada a una API, envío de un formulario, notificación, escritura en una base de datos
5. **Persistencia:** guardar el nuevo estado para la siguiente ejecución
6. **Repetición o finalización,** según el patrón de ejecución

Taxonomía de softbots según su función

- **De recolección de información:** agregadores de noticias, comparadores de precios
- **De monitorización:** vigilar disponibilidad, cambios de precio, menciones de marca
- **De interacción transaccional:** rellenar formularios, realizar compras o reservas automatizadas
- **De asistencia conversacional:** chatbots y asistentes que combinan percepción externa con generación de lenguaje natural

Esta taxonomía no es excluyente: muchos softbots reales combinan varias de estas funciones a la vez.

Bloque 4


Programación de softbots

Patrones de ejecución: polling vs. eventos

Dos formas fundamentales de organizar cuándo actúa un softbot:

- **Polling (sondeo):** el softbot pregunta periódicamente "¿ha cambiado algo?", simple de implementar, pero ineficiente si los cambios son poco frecuentes
- **Orientado a eventos (webhooks):** el softbot espera pasivamente a que le avisen cuando algo ocurre — más eficiente, pero requiere que el servicio externo lo soporte y que el softbot exponga un punto de recepción

La elección condiciona directamente la arquitectura: un softbot por **polling** se parece a un bucle reactivo simple; uno orientado a eventos se parece más a un sistema dirigido por mensajes.



Programación de tareas

Cuando el softbot debe ejecutarse de forma periódica, se usan planificadores:

- **cron** (Linux) o el Programador de tareas (Windows) para ejecuciones a nivel de sistema operativo
- Bibliotecas de planificación dentro de la propia aplicación (p. ej. **APScheduler** en Python), útiles cuando el softbot necesita gestionar su propio calendario de tareas con lógica más compleja

```
# Ejemplo con APScheduler
from apscheduler.schedulers.blocking import BlockingScheduler

scheduler = BlockingScheduler()
scheduler.add_job(revisar_precios, 'interval', hours=1)
scheduler.start()
```

Programación asíncrona

Un softbot suele hacer **muchas** peticiones de red, y cada una implica esperar. Ejecutarlas de una en una es lento e ineficiente.

- La programación **asíncrona** permite lanzar varias peticiones y seguir trabajando mientras se espera la respuesta
- En Python, esto se implementa con `asyncio` y bibliotecas compatibles como `aiohttp` o `httpx`

Programación asíncrona: asyncio y httpx

```
import asyncio, httpx

async def obtener(cliente, url):
    respuesta = await cliente.get(url)
    return respuesta.json()

async def main():
    async with httpx.AsyncClient() as cliente:
        tareas = [obtener(cliente, url) for url in urls]
        return await asyncio.gather(*tareas)
```

Gestión segura de credenciales

Las claves de API, contraseñas o tokens **nunca** deben:

- Escribirse directamente en el código fuente
- Subirse a un repositorio de control de versiones

En su lugar:

- **Variables de entorno**
- **Ficheros de configuración** excluidos del repositorio (`.gitignore`)
- **Gestores de secretos** dedicados en entornos de producción (Vault, AWS Secrets Manager, etc.)

Esto conecta con el **principio de mínimo privilegio**: un softbot debe tener acceso solo a lo estrictamente necesario para su tarea.

Buenas prácticas de diseño para un softbot

- **Principio de mínimo privilegio:** solo los permisos y accesos estrictamente necesarios
- **Límites de tasa propios,** aunque el servicio externo no los exija explícitamente
- **Transparencia:** identificarse honestamente (user-agent, cabeceras) en lugar de disfrazarse como humano cuando no hace falta
- **Respeto a los términos de servicio** del sitio o API con el que se interactúa
- **Degradación controlada:** que un fallo parcial no tumbe todo el softbot

Bloque 5

Caso práctico

Ejemplo: monitor de precios

Diseñemos, a alto nivel, un softbot que vigile el precio de un producto y avise cuando baje de un umbral:

1. **Percepción:** cada hora (`cron/APScheduler`), consulta la API del comercio si existe; si no, hace scraping de la página del producto con `requests` + `BeautifulSoup`
2. **Decisión:** arquitectura reactiva simple: «si $\text{precio actual} < \text{umbral}$, notificar» (se podría sofisticar con una arquitectura BDI si quisiéramos gestionar varios productos con distintas prioridades)
3. **Acción:** envío de una notificación (correo, API de mensajería)
4. **Persistencia:** guarda el último precio visto en una base de datos ligera, para poder calcular tendencias

Recorriendo el ciclo percepción-decisión-acción

Fase	Bloque 1/4.1	Implementación en este caso
Percepción	API o scraping	<code>requests</code> + <code>BeautifulSoup</code> , o llamada REST
Decisión	Arquitectura (4.1)	Regla condición-acción (reactiva)
Acción	Actuador	Envío de email / API de notificaciones
Persistencia	Estado (Bloque 4)	Base de datos SQLite
Robustez	Manejo de errores	Reintentos con backoff si el sitio no

Este ejemplo, aunque sencillo, contiene ya todos los elementos que hemos visto

¡GRACIAS!

Referencias

Referencias (I)

Fielding, R. T. (2000). **Architectural styles and the design of network-based software architectures** [Tesis doctoral, University of California, Irvine].

Foundation for Intelligent Physical Agents. (2002). **FIPA ACL message structure specification**.

Hypertext Transfer Protocol Version 2 (HTTP/2), RFC 7540. (2015). IETF.
<https://datatracker.ietf.org/doc/html/rfc7540>

Robots Exclusion Protocol, RFC 9309. (2022). IETF. <https://www.rfc-editor.org/rfc/rfc9309>

Reglamento (UE) 2024/1689 del Parlamento Europeo y del Consejo, de 13 de junio de 2024, por el que se establecen normas armonizadas en materia de inteligencia artificial (Reglamento de IA). (2024). Diario Oficial de la Unión Europea.

Referencias (II)

hiQ Labs, Inc. v. LinkedIn Corp., 31 F.4th 1180 (9th Cir. 2022).

Ley 34/2002, de 11 de julio, de Servicios de la Sociedad de la Información y de Comercio Electrónico (LSSI-CE). (2002). Boletín Oficial del Estado.

Reglamento (UE) 2016/679 del Parlamento Europeo y del Consejo, de 27 de abril de 2016, relativo a la protección de las personas físicas en lo que respecta al tratamiento de datos personales (RGPD). (2016). Diario Oficial de la Unión Europea.

W3C. (1999). **XML Path Language (XPath) version 1.0**.
<https://www.w3.org/TR/1999/REC-xpath-19991116/>

Referencias (III)

Astro. (2025, diciembre 9). **New AI web standards and scraping trends in 2026: Rethinking robots.txt**. DEV Community. <https://dev.to/astro-official/new-ai-web-standards-and-scraping-trends-in-2026-rethinking-robotstxt-3730>

Browserless. (2026, enero 10). **Is web scraping legal in 2026? Laws, ethics, and risks explained**. <https://www.browserless.io/blog/is-web-scraping-legal>

Byzov, A. (2026). **Robots.txt, AI crawlers & web scraping in 2026**. DataImpulse. <https://dataimpulse.com/blog/robots-txt-ai-crawlers/>

Cloro. (2026). **Is web scraping legal? 7-country 2026 compliance guide**. <https://cloro.dev/blog/website-scraping-legal/>

Referencias (IV)

Documentación oficial de `requests`. <https://requests.readthedocs.io>

Documentación oficial de Playwright para Python. <https://playwright.dev/python/>

Documentación oficial de Scrapy. <https://docs.scrapy.org>

Documentación oficial de Selenium. <https://www.selenium.dev>

Yao, S., Zhao, J., Yu, D., Du, N., Shafran, I., Narasimhan, K., & Cao, Y. (2023). ReAct: Synergizing reasoning and acting in language models. En **Proceedings of the Eleventh International Conference on Learning Representations (ICLR 2023)**.